

Prática em R - Aula 05

Distribuição a posteriori no modelo Normal

Prof. Fabio Cop (*fcferreira@unifesp.br*)

Instituto do Mar - Unifesp

2026-05-04

Conteúdo

1	Exploração inicial do conjunto de dados	2
1.1	Visualização da distribuição	2
2	Distribuições a priori e checagem preditiva a priori	3
2.1	Visualização da distribuição preditiva a priori	4
3	Ajuste do modelo com brms	5
4	Distribuições a posteriori dos parâmetros	5
4.1	Resumo numérico dos parâmetros	5
4.2	Visualização das distribuições marginais a posteriori	6
4.3	Distribuição a posteriori conjunta	6
5	Distribuição preditiva a posteriori	7
5.1	Checagem preditiva a posteriori	7
5.2	Predição para novas observações	7

1 Exploração inicial do conjunto de dados

O dataset Howell1 (McElreath 2020) registra dados antropométricos de 544 indivíduos !Kung San do deserto de Kalahari, coletados pela antropóloga Nancy Howell. As variáveis disponíveis são **height** (altura em cm), **weight** (peso em kg), **age** (idade em anos) e **male** (indicador de sexo). Neste laboratório, o foco recai sobre a variável **height** dos 352 adultos com 18 anos ou mais.

O objetivo inicial é examinar a distribuição das alturas antes de qualquer ajuste de modelo, identificar as características da variável e avaliar se a Distribuição Normal é um modelo generativo plausível para esses dados.

Código

```
# Carregar os pacotes
library(tidyverse)
library(patchwork)
library(posterior)
library(brms)

# Carregar os dados
dados <- read_csv("https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography.csv",
                  sep = ";")

# Subset de adultos (age >= 18)
adultos <- dados[dados$age >= 18, ]

# Resumo descritivo das variáveis
head(adultos)
summary(adultos[, c("height", "weight", "age")])
```

O que observar

- Examine a diferença entre a média e a mediana de **height**. O que essa diferença (ou semelhança) sugere sobre a assimetria da distribuição?
- Em que faixa de alturas se concentra a maioria dos adultos? Como essa faixa se compara com o desvio padrão calculado?

1.1 Visualização da distribuição

Código

```
# Histograma com curva de densidade e curva Normal teórica sobreposta
media_h <- mean(adultos$height)
dp_h <- sd(adultos$height)

ggplot(adultos, aes(x = height)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
                fill = "steelblue", color = "white",
                linewidth = 0.2, alpha = 0.7) +
  geom_density(color = "steelblue4", linewidth = 1) +
  labs(x = "Altura (cm)", y = "Densidade",
       title = "Distribuição das alturas - adultos !Kung San",
       subtitle = paste0("n = ", nrow(adultos),
                        " | média = ", round(media_h, 1),
```

```

" cm | dp = ", round(dp_h, 1), " cm")) +
theme_minimal(base_size = 12)

```

O que observar

- A curva de densidade empírica (azul escuro) e a curva Normal teórica (laranja tracejada) se sobrepõem bem? Em que regiões da distribuição há maior divergência?
- A forma do histograma justifica o uso da Distribuição Normal como modelo? Identifique características que apoiam ou questionam essa escolha.

2 Distribuições a priori e checagem preditiva a priori

Antes de observar os dados como evidência para estimar os parâmetros, é necessário especificar as distribuições a priori para μ e σ . As distribuições a priori expressam o conhecimento disponível sobre os parâmetros antes de qualquer dado ser incorporado ao modelo.

O modelo generativo para alturas de adultos é:

$$\begin{aligned}
 Y &\sim \text{Normal}(\mu, \sigma) \\
 \mu &\sim \text{Normal}(160, 20) \\
 \sigma &\sim \text{Exponencial}(0,1)
 \end{aligned}$$

A distribuição a priori $\text{Normal}(160, 20)$ para μ concentra a probabilidade em uma faixa de alturas biologicamente razoável para adultos humanos, cobrindo com probabilidade substancial o intervalo de 120 a 200 cm. A distribuição a priori $\text{Exponencial}(0,1)$ para σ garante que o desvio padrão permaneça estritamente positivo e concentra a probabilidade abaixo de 30 cm, com valor esperado de 10 cm.

A checagem preditiva a priori verifica se as distribuições a priori, tomadas em conjunto, geram dados com características compatíveis com o fenômeno estudado. Para isso, ajusta-se o modelo sem incorporar os dados observados como evidência, amostrando exclusivamente das distribuições a priori especificadas.

Código

```

# Definição explícita das distribuições a priori
prioris <- c(
  prior(normal(160, 20),    class = Intercept), # priori para mu
  prior(exponential(0.1),   class = sigma)      # priori para sigma
)

# Ajuste com sample_prior = "only": amostra apenas das distribuições a priori
fit_prior <- brm(
  formula = height ~ 1,
  family  = gaussian(),
  prior   = prioris,
  data    = adultos,
  sample_prior = "only",
  chains  = 4,
  iter    = 1000,
  warmup  = 500,
  refresh = 0
)

```

O que observar

- Analise o papel do argumento `sample_prior = "only"` no comportamento do ajuste. Em que aspecto fundamental esse ajuste difere de um `brm()` padrão que incorpora os dados?

- Com base nas distribuições a priori especificadas, que faixa de alturas o modelo considera plausível antes de ver os dados?

2.1 Visualização da distribuição preditiva a priori

Código: distribuição a priori de μ e σ

```
prior_params <- as_draws_df(fit_prior)

# b_Intercept corresponde a mu
prior_mu <- ggplot(prior_params, aes(x = b_Intercept)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40,
    fill = "steelblue", color = "white", linewidth = 0.2, alpha = 0.6) +
  geom_density(color = "steelblue4", linewidth = 1) +
  labs(x = expression(mu ~ "(cm)"), y = "Densidade",
    title = expression("Distribuição marginal de " ~ mu)) +
  theme_minimal(base_size = 12)

prior_sigma <- ggplot(prior_params, aes(x = sigma)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40,
    fill = "orange", color = "white", linewidth = 0.2, alpha = 0.6) +
  geom_density(color = "darkorange4", linewidth = 1) +
  labs(x = expression(sigma ~ "(cm)"), y = "Densidade",
    title = expression("Distribuição marginal de " ~ sigma)) +
  theme_minimal(base_size = 12)

prior_mu + prior_sigma
```

Código: distribuição a priori preditiva

```
amostras_prior <- data.frame(
  prior_pred = as.vector(posterior_predict(fit_prior))
)

# Checagem preditiva a priori
ggplot(amostras_prior, aes(x = prior_pred)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40,
    alpha = 0.5, color = "white", fill = "#aec6cf") +
  geom_density(linewidth = 0.9, fill = NA) +
  labs(x = "Altura (cm)", y = "Densidade") +
  theme_minimal(base_size = 12) +
  theme(strip.text = element_text(face = "bold", size = 11))
```

O que explorar

- O intervalo de alturas gerado pela distribuição preditiva a priori engloba valores biologicamente impossíveis (alturas negativas ou extremamente elevadas)? O que isso indica sobre o grau de informatividade das distribuições a priori escolhidas?
- Altere o desvio padrão da distribuição a priori de μ de 20 para 100 (`normal(160, 100)`) e reajuste o modelo com `sample_prior = "only"`. Como a distribuição preditiva a priori se altera?

3 Ajuste do modelo com brms

Com as distribuições a priori verificadas, o modelo é ajustado incorporando os dados observados. O `brms` compila o modelo em C++ e utiliza HMC para amostrar da distribuição a posteriori dos parâmetros. O resultado é um conjunto de amostras da distribuição a posteriori que resume o que o modelo aprendeu sobre μ e σ à luz dos dados.

Código

```
# Ajuste do modelo com os dados observados
fit <- brm(
  formula = height ~ 1,
  family  = gaussian(),
  prior   = prioris,
  data    = adultos,
  chains  = 4,
  iter    = 1000,
  warmup  = 500,
  refresh = 0
)
```

Visualize o resultado:

```
# Visualizar o sumário do ajuste
summary(fit)
```

O que observar

- O sumário apresenta as estimativas para `b_Intercept` (correspondente a μ) e `sigma`. Quais são os valores centrais estimados para cada parâmetro?
- As colunas `l-89%` e `u-89%` do sumário delimitam o intervalo de credibilidade de 89%. O que esse intervalo indica sobre a precisão com que os dados determinam μ ?

4 Distribuições a posteriori dos parâmetros

A distribuição a posteriori é o produto central da estimação bayesiana. Ela expressa a incerteza residual sobre cada parâmetro após combinar as distribuições a priori com as evidências dos dados. Nesta seção, os parâmetros μ e σ são explorados por meio de resumos numéricos e visualizações.

4.1 Resumo numérico dos parâmetros

Código

```
# Extrair amostras da distribuição a posteriori em formato tidy
amostras <- as_draws_df(fit)

# Resumo detalhado: média, dp e intervalos de credibilidade de 89%
amostras |>
  subset_draws(variable = c("b_Intercept", "sigma")) |>
  summarise_draws(
    mean, median, sd,
    ~quantile(.x, c(0.055, 0.945))
  )

# Intervalo de credibilidade de 89% via posterior_interval()
posterior_interval(fit, prob = 0.89,
  variable = c("b_Intercept", "sigma"))
```

O que observar

- Examine a amplitude do intervalo de credibilidade de 89% para `b_Intercept` e para `sigma`. O que cada intervalo informa sobre o respectivo parâmetro e o que ele descreve no contexto do modelo?
- O desvio padrão da distribuição a posteriori de `b_Intercept` é consideravelmente menor do que o valor estimado de `sigma`. Que diferença conceitual entre os dois parâmetros explica essa discrepância de magnitude?

4.2 Visualização das distribuições marginais a posteriori

Código

```
# Distribuições marginais a posteriori para mu e sigma
p_mu <- ggplot(amostras, aes(x = b_Intercept)) +
  geom_histogram(aes(y = after_stat(density)), bins = 50,
    fill = "steelblue", color = "white",
    linewidth = 0.2, alpha = 0.7) +
  geom_density(color = "steelblue4", linewidth = 1) +
  geom_vline(xintercept = as.vector(posterior_interval(fit, prob = 0.89,
    variable = "b_Intercept")),
    linetype = "dashed", color = "gray40") +
  labs(x = expression(mu ~ "(cm)"), y = "Densidade",
    title = expression("Distribuição a posteriori de " ~ mu)) +
  theme_minimal(base_size = 12)

p_sigma <- ggplot(amostras, aes(x = sigma)) +
  geom_histogram(aes(y = after_stat(density)), bins = 50,
    fill = "orange", color = "white",
    linewidth = 0.2, alpha = 0.7) +
  geom_density(color = "darkorange4", linewidth = 1) +
  geom_vline(xintercept = as.vector(posterior_interval(fit, prob = 0.89,
    variable = "sigma")),
    linetype = "dashed", color = "gray40") +
  labs(x = expression(sigma ~ "(cm)"), y = "Densidade",
    title = expression("Distribuição a posteriori de " ~ sigma)) +
  theme_minimal(base_size = 12)

p_mu + p_sigma
```

O que observar

- As linhas tracejadas delimitam o intervalo de credibilidade de 89%. Que fração das amostras da distribuição a posteriori está contida entre essas linhas?
- A distribuição a posteriori de μ é consideravelmente mais estreita do que a distribuição a priori $\text{Normal}(160, 20)$. O que esse estreitamento indica sobre o efeito dos dados no conhecimento sobre μ ?

4.3 Distribuição a posteriori conjunta

Código

```
# Gráfico de dispersão das amostras conjuntas (mu, sigma)
ggplot(amostras, aes(x = b_Intercept, y = sigma)) +
  geom_point(alpha = 0.15, color = "#1a9988", size = 0.8) +
  geom_density_2d(color = "gray30", linewidth = 0.4) +
  labs(x = expression(mu ~ "(cm)"), y = expression(sigma ~ "(cm)"),
    title = "Distribuição a posteriori conjunta de  $\mu$  e  $\sigma$ ") +
```

```
theme_minimal(base_size = 12)
```

O que observar

- As amostras de μ e σ formam uma nuvem de pontos com estrutura visível. Existe correlação entre os dois parâmetros a posteriori? O que isso indicaria sobre a relação entre a estimativa da média e a estimativa da variabilidade?
- Compare a região ocupada pelas amostras com o espaço total de valores plausíveis para (μ, σ) . Como $n = 352$ observações delimitam essa região?

5 Distribuição preditiva a posteriori

A distribuição a posteriori dos parâmetros descreve o que o modelo aprendeu sobre μ e σ . A distribuição preditiva a posteriori vai além: ela descreve a distribuição de novas alturas $\tilde{y}$, propagando simultaneamente a variabilidade individual das alturas e a incerteza residual sobre os parâmetros.

A checagem preditiva a posteriori verifica se os dados que o modelo consegue gerar são compatíveis com os dados que foram realmente observados. Essa comparação é uma das ferramentas centrais para avaliar a adequação do modelo.

5.1 Checagem preditiva a posteriori

Código

```
# Checagem preditiva a posteriori: sobreposição de distribuições simuladas
# (linhas azul-claras) sobre os dados observados (linha escura)
pp_check(fit, ndraws = 100) +
  labs(title = "Checagem preditiva a posteriori - modelo Normal",
        x = "Altura (cm)", y = "Densidade") +
  theme_minimal(base_size = 12)

# Checagem alternativa: comparação de estatísticas resumo
pp_check(fit, type = "stat", stat = "mean", ndraws = 1000) +
  labs(title = "Distribuição preditiva a posteriori da média",
        x = "Média simulada (cm)") +
  theme_minimal(base_size = 12)

pp_check(fit, type = "stat", stat = "sd", ndraws = 1000) +
  labs(title = "Distribuição preditiva a posteriori do DP",
        x = "Desvio padrão simulado (cm)") +
  theme_minimal(base_size = 12)
```

O que observar

- No primeiro gráfico, as distribuições simuladas (linhas azul-claras) cobrem bem a distribuição dos dados observados (linha escura)? Em que regiões da distribuição o modelo apresenta maior ou menor ajuste?
- Nos gráficos de estatísticas resumo, onde se posiciona o valor observado (linha vertical) em relação à distribuição de valores simulados? O modelo reproduz adequadamente a média e o desvio padrão dos dados?

5.2 Predição para novas observações

Código

```
# Gerar amostras da distribuição preditiva a posteriori
y_pred <- posterior_predict(fit, ndraws = 1000)
```

```

# Converter para vetor (todas as predições)
y_pred_vec <- as.vector(y_pred)

# Comparar dados observados com predições
dados_comp <- data.frame(
  valor = c(adultos$height, y_pred_vec),
  fonte = c(rep("Observado", nrow(adultos)),
             rep("Preditiva a posteriori", length(y_pred_vec)))
)

ggplot(dados_comp, aes(x = valor, fill = fonte)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40,
                 alpha = 0.5, color = "white",
                 linewidth = 0.2, position = "identity") +
  scale_fill_manual(values = c("Observado" = "steelblue",
                              "Preditiva a posteriori" = "#e6a073")) +
  labs(x = "Altura (cm)", y = "Densidade", fill = NULL,
       title = "Dados observados e distribuição preditiva a posteriori") +
  facet_wrap(vars(fonte), nrow = 2) +
  theme_minimal(base_size = 12) +
  theme(legend.position = "top")

```

O que observar

- A distribuição preditiva a posteriori é mais larga do que a distribuição dos dados observados. Quais são as duas fontes de variação que tornam a distribuição preditiva mais larga do que os dados isolados?
- Se o modelo não estivesse capturando bem a variabilidade dos dados, como a distribuição preditiva a posteriori se diferenciaria da distribuição observada?

McElreath, Richard. 2020. *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. 2^o ed. Chapman; Hall/CRC.