

Prática em R - Aula 07

Análise exploratória e visualização de dados

Prof. Fabio Cop (*fcferreira@unifesp.br*)

Instituto do Mar - Unifesp

2026-04-24

Conteúdo

1	Morfometria de passeriformes — distribuição univariada e comparações entre grupos	2
1.1	Carregamento e inspeção inicial	2
1.2	Histograma e escolha de intervalos	2
1.3	Curva de densidade	3
1.4	Diagrama de caixa com pontos individuais sobrepostos	3
2	Morfometria de passeriformes — relações bivariadas e estrutura multivariada	4
2.1	Diagrama de dispersão com variável de grupo	4
2.2	Gráfico de pares das variáveis morfométricas	4
2.3	Gráfico de pares separado por grupo	5
3	Bioluminescência oceânica — variação entre unidades amostrais	5
3.1	Padrão global profundidade-bioluminescência	5
3.2	Variação entre estações com facetas	6
4	Séries temporais e dependência temporal	6
4.1	Gráfico de série temporal	6
4.2	Comparação de múltiplas séries com facetas	6
4.3	Função de autocorrelação	7

1 Morfometria de passeriformes — distribuição univariada e comparações entre grupos

O dataset de morfometria de passeriformes de Zuur et al. (2009), arquivo `Sparrows.txt`, registra medidas de comprimento de asa (`wingcrd`), comprimento do tarso (`tarsus`), comprimento do crânio (`head`) e peso corporal (`wt`) para um conjunto de indivíduos, além de variáveis categóricas de sexo (`Sex`, codificada como inteiro) e classe etária (`Age`, também codificada como inteiro). O arquivo usa separador de tabulação.

As atividades desta seção cobrem a exploração da distribuição de variáveis morfométricas individualmente e a comparação dessas distribuições entre grupos. Construa cada visualização de forma independente antes de interpretar os padrões.

1.1 Carregamento e inspeção inicial

Código

Carregue o arquivo com a função `read.table()`, usando `header = TRUE` e `sep = "\t"`. A URL de acesso ao arquivo é:

https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography/zuur-2009/zuur-2009-data-sets/Sparrows.txt

Após o carregamento, explore o dataset com as três funções a seguir.

- `str()`: examina o tipo de cada coluna e exibe os primeiros valores.
- `summary()` aplicado às colunas `wingcrd`, `tarsus`, `head` e `wt`: produz o resumo numérico das variáveis morfométricas.
- `table()` aplicado às colunas `Sex` e `Age` separadamente: conta o número de observações em cada categoria.

O que observar

- No resultado de `str()`, identifique quais variáveis são numéricas e quais são codificadas como inteiros representando categorias. Essa distinção importa para o mapeamento de cores em `ggplot2`.
- No `summary()`, compare o intervalo de cada variável morfométrica. Para qual variável a diferença entre valor máximo e mínimo é maior em relação à sua mediana?
- A distribuição de machos e fêmeas no dataset é equilibrada ou um dos sexos concentra a maioria das observações?

1.2 Histograma e escolha de intervalos

O parâmetro `bins` do `geom_histogram()` controla o número de intervalos do histograma. A escolha do número de intervalos afeta a percepção da forma da distribuição: intervalos em excesso criam variações que dificultam identificar o padrão geral, enquanto intervalos insuficientes suavizam a distribuição a ponto de ocultar detalhes relevantes.

Código

Construa três histogramas do peso corporal (`wt`) usando `ggplot()` com `geom_histogram()`, variando o argumento `bins` entre os valores 10, 30 e 60. Em cada versão:

- Mapeie `wt` ao eixo x dentro de `aes()`.
- Use os argumentos `fill` e `color` de `geom_histogram()` para definir a cor de preenchimento das barras e a cor da borda.
- Adicione rótulos aos eixos com `labs()` e aplique `theme_bw()`.

Para exibir os três gráficos lado a lado, carregue o pacote **patchwork** e combine os objetos gerados com o operador **+**.

O que explorar

- Em qual das três versões o padrão geral da distribuição de peso corporal fica mais claro?
- Com `bins = 60`, o histograma parece revelar mais detalhes ou mais ruído em relação à versão com `bins = 30`?
- A distribuição do peso corporal parece simétrica em torno de um valor central ou apresenta assimetria? Há barras isoladas nas extremidades que possam indicar valores muito distantes do padrão geral?

1.3 Curva de densidade

A curva de densidade é uma versão suavizada do histograma representada como uma curva contínua com área total igual a 1. Ela facilita a comparação da distribuição de uma variável entre grupos na mesma visualização, pois as curvas se sobrepõem de forma contínua sem a interferência visual das barras adjacentes.

Código

Construa uma curva de densidade do peso corporal com `ggplot()` e `geom_density()`. Mapeie `factor(Sex)` ao argumento `fill` dentro de `aes()` para separar os grupos por cor. Ajuste o argumento `alpha` em `geom_density()` para tornar as curvas semitransparentes e permitir visualizar as regiões de sobreposição entre os grupos. Adicione rótulos com `labs()` e aplique `theme_bw()`.

Em seguida, posicione o gráfico de densidade ao lado do histograma do peso corporal construído na seção anterior, usando **patchwork**. Para o histograma nessa comparação, use `bins = 30` e mapeie `factor(Sex)` ao argumento `fill` para separar os grupos. Adicione `facet_wrap(~ Sex)` ao histograma para exibir um painel por grupo.

O que observar

- As curvas de densidade para machos e fêmeas estão separadas ou se sobrepõem em uma faixa ampla?
- Qual dos dois grupos apresenta curva mais larga, indicando maior dispersão do peso corporal?
- Para comparar a sobreposição entre grupos, qual das duas visualizações você considera mais clara: o histograma com facetas ou a curva de densidade sobreposta?

1.4 Diagrama de caixa com pontos individuais sobrepostos

O diagrama de caixa resume a distribuição de uma variável contínua por meio de cinco descritores: o primeiro quartil (Q_1), a mediana, o terceiro quartil (Q_3), as hastes que se estendem até 1,5 vezes o intervalo interquartil além das bordas da caixa e os pontos além das hastes. A sobreposição dos pontos individuais com `geom_jitter()` torna visível a distribuição real dentro de cada grupo, revelando concentrações e padrões que a caixa isolada não evidencia.

Código

Construa um diagrama de caixa do peso corporal por sexo usando `ggplot()` com `geom_boxplot()`. Mapeie `factor(Sex)` ao eixo x e ao argumento `fill` dentro de `aes()`. Use `outlier.shape = NA` em `geom_boxplot()` para suprimir a marcação automática de valores atípicos, pois os pontos individuais serão exibidos pela camada seguinte. Defina `alpha` para tornar a caixa semitransparente.

Adicione uma camada `geom_jitter()` sobre o diagrama de caixa, ajustando `width`, `alpha` e `size` para equilibrar a visibilidade dos pontos e a sobreposição. Finalize com `labs()` para nomear os eixos e `theme_bw()`.

O que observar

- A mediana de machos e fêmeas está em alturas semelhantes ou uma é visivelmente mais alta

do que a outra?

- As caixas dos dois grupos se sobrepõem ou estão separadas? Que proporção do intervalo interquartil de um grupo se encontra dentro do intervalo interquartil do outro?
- Os pontos individuais revelam alguma concentração dentro de cada grupo que a caixa não mostra?

2 Morfometria de passeriformes — relações bivariadas e estrutura multivariada

Com a distribuição de cada variável examinada individualmente e as comparações entre grupos realizadas, o passo seguinte é explorar as relações entre pares de variáveis morfométricas. O diagrama de dispersão mostra a direção, a força e a forma de cada relação entre dois pares de variáveis. O gráfico de pares organiza todas as combinações possíveis em uma grade, permitindo uma inspeção multivariada em uma única visualização.

2.1 Diagrama de dispersão com variável de grupo

O mapeamento de uma variável categórica à cor dos pontos acrescenta uma terceira dimensão ao diagrama de dispersão, permitindo verificar se a relação entre as variáveis contínuas varia entre os grupos.

Código

Construa um diagrama de dispersão usando `ggplot()` com `geom_point()`. Mapeie `tarsus` ao eixo `x`, `wingcrd` ao eixo `y` e `factor(Sex)` ao argumento `color`, todos dentro de `aes()`. Use `alpha` em `geom_point()` para reduzir a sobreposição visual dos pontos. Nomeie os eixos e a legenda com `labs()` e aplique `theme_bw()`.

O que observar

- A relação entre comprimento do tarso e comprimento de asa é aproximadamente linear ou apresenta curvatura visível?
- A dispersão em torno da relação geral é uniforme ao longo dos valores de `tarsus` ou aumenta conforme o comprimento cresce? Uma dispersão crescente com o preditor é chamada de heterocedasticidade.
- Machos e fêmeas ocupam regiões distintas do espaço tarso-asa ou as nuvens de pontos se sobrepõem amplamente?

2.2 Gráfico de pares das variáveis morfométricas

O gráfico de pares exibe, em uma grade, todos os diagramas de dispersão possíveis entre p variáveis, além da distribuição de cada variável na diagonal. Com quatro variáveis morfométricas, a grade contém $\frac{4 \times 3}{2} = 6$ pares distintos.

Código

Carregue o pacote `GGally`. Caso ele não esteja instalado no ambiente do projeto, execute `renv::install("GGally")` uma única vez antes de prosseguir.

Use `select()` do pacote `dplyr` para extrair as colunas `wingcrd`, `tarsus`, `head` e `wt` do dataset. Encadeie com o operador pipe nativo do R (`|>`) e passe o resultado para `ggpairs()` com `aes(alpha = 0.3)`.

O que observar

- Identifique o par de variáveis com o maior coeficiente de correlação exibido na parte superior da grade. O diagrama de dispersão correspondente confirma essa associação visualmente?
- Alguma variável apresenta distribuição claramente assimétrica na diagonal da grade? Uma assimetria marcante pode indicar a necessidade de transformação antes da modelagem.
- Há pares de variáveis com coeficiente de correlação próximo de zero? O que isso implica sobre

a informação que cada variável acrescenta a um modelo preditivo?

2.3 Gráfico de pares separado por grupo

O argumento `color` dentro do `aes()` de `ggpairs()` aplica a separação por grupo simultaneamente a todos os painéis da grade, permitindo comparar tanto as relações bivariadas quanto as distribuições individuais entre os grupos.

Código

Repita o procedimento da seção anterior, incluindo a coluna `Age` na chamada de `select()`. Mapeie `factor(Age)` ao argumento `color` dentro do `aes()` de `ggpairs()`, mantendo `alpha = 0.3`.

Em seguida, repita a análise substituindo `Age` por `Sex` no mapeamento de cor. Para isso, inclua `Sex` no `select()` e ajuste o `aes()` de acordo.

O que explorar

- As correlações entre as variáveis morfométricas variam entre classes etárias? Compare os coeficientes de correlação exibidos na parte superior da grade para cada grupo.
- As distribuições na diagonal diferem em localização ou dispersão entre as classes etárias?
- Ao substituir `Age` por `Sex`, as diferenças entre grupos tornam-se mais ou menos pronunciadas do que no agrupamento por idade?

3 Bioluminescência oceânica — variação entre unidades amostrais

O dataset de bioluminescência oceânica de Zuur et al. (2009), arquivo `ISIT.txt`, registra contagens de fontes bioluminescentes (`Sources`) em diferentes profundidades de amostragem (`SampleDepth`) em estações do Atlântico Norte. Cada estação (`Station`) corresponde a um local geográfico com múltiplas amostras coletadas em diferentes profundidades. A relação entre profundidade e bioluminescência pode variar entre estações em função de diferenças oceanográficas locais. Examinar se esse padrão é consistente entre locais motiva abordagens de modelagem que estimam a variação entre grupos de forma explícita.

3.1 Padrão global profundidade-bioluminescência

Código

Carregue o arquivo `ISIT.txt` com `read.table()`, usando `header = TRUE` e `sep = "\t"`. A URL de acesso é:

https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography/zuur-2009/zuur-2009-data-sets/ISIT.txt

Inspecione as variáveis com `str()`. Construa um diagrama de dispersão com `ggplot()` e `geom_point()`, mapeando `SampleDepth` ao eixo x e `Sources` ao eixo y . Ajuste `alpha` e `size` para lidar com a sobreposição de pontos. Nomeie os eixos com `labs()` e aplique `theme_bw()`.

O que observar

- Existe uma tendência visível entre profundidade de amostragem e número de fontes bioluminescentes no padrão global?
- A dispersão dos pontos em torno da tendência geral é pequena e uniforme ou ampla e heterogênea? Alta dispersão pode indicar que estações diferentes apresentam relações distintas com a profundidade.

3.2 Variação entre estações com facetas

Código

Parta do gráfico construído na seção anterior. Acrescente `facet_wrap(~ Station)` como uma camada adicional para dividir o gráfico em painéis por estação amostral. Mantenha os mesmos mapeamentos estéticos, rótulos de eixo e tema.

O que observar

- A relação profundidade-bioluminescência é consistente entre as estações ou algumas apresentam padrões claramente distintos das demais?
- A profundidade máxima amostrada varia entre estações, resultando em painéis com diferentes extensões no eixo x . Em quais estações a relação é mais pronunciada?
- Compare a variação dentro de cada painel com a variação entre os painéis. Em qual escala a variabilidade parece maior?

4 Séries temporais e dependência temporal

O dataset de abundâncias de aves aquáticas no Havaí de Zuur et al. (2009), arquivo `Hawaii.txt`, registra contagens anuais de populações de aves endêmicas nas ilhas do Havaí entre 1956 e 2003: pernilongos (`Stilt`) em Oahu e Maui, galinhas-d'água (`Coot`) em Oahu e Maui e galinhola (`Moorhen`) em Kauai. O arquivo também inclui a precipitação anual (`Rainfall`).

O gráfico de série temporal representa uma variável medida repetidamente ao longo do tempo, conectando pontos com linhas para evidenciar tendências de aumento ou redução, flutuações e irregularidades pontuais. Observações coletadas em sequência temporal tendem a ser mais semelhantes entre si quanto mais próximas estiverem no tempo, propriedade chamada de dependência temporal. Essa característica tem implicações importantes para a análise estatística, pois viola a suposição de independência entre observações dos modelos convencionais.

4.1 Gráfico de série temporal

Código

Carregue o arquivo `Hawaii.txt` com `read.table()` usando `header = TRUE` e `sep = "\t"`. A URL de acesso é:

```
https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography/zuur-2009/zuur-2009-data-sets/Hawaii.txt
```

Inspeção as variáveis com `str()`. Construa um gráfico de série temporal da coluna `Moorhen.Kauai` ao longo dos anos com `ggplot()`. Use `geom_line()` para conectar os pontos com uma linha e `geom_point()` para destacar cada observação anual. Mapeie `Year` ao eixo x e `Moorhen.Kauai` ao eixo y . Defina a cor em ambas as camadas, adicione rótulos de eixo com `labs()` e aplique `theme_bw()`.

O que observar

- A abundância de galinhola em Kauai aumenta, diminui ou permanece estável ao longo do período registrado?
- Há algum intervalo de tempo em que a tendência muda de direção ou ocorrem quedas abruptas seguidas de recuperação?
- O padrão geral parece uma tendência contínua ao longo de todo o período ou apresenta variações pontuais em torno de um valor relativamente estável?

4.2 Comparação de múltiplas séries com facetas

Quando o dataset contém várias séries temporais, é possível reorganizá-las em formato longo e construir gráficos com facetas, preservando a mesma escala de tempo para comparação visual direta entre as séries. O argumento `scales = "free_y"` em `facet_wrap()` permite que cada painel tenha sua própria escala vertical, facilitando a leitura de tendências relativas quando as séries têm magnitudes muito diferentes entre si.

Código

Carregue o pacote `tidyr`. Use `select()` para extrair as colunas `Year`, `Stilt.Oahu`, `Stilt.Maui`, `Coot.Oahu` e `Coot.Maui`. Encadeie com `pivot_longer()` para reorganizar as quatro séries em formato longo. No `pivot_longer()`, use `-Year` para indicar que essa coluna permanece como identificador, e nomeie as novas colunas resultantes (uma para o nome da série, outra para os valores de abundância).

Com os dados reorganizados, construa um gráfico com `geom_line()` e aplique `facet_wrap()` usando a coluna de nomes das séries. Inclua `scales = "free_y"` no `facet_wrap()`. Adicione rótulos de eixo com `labs()` e aplique `theme_bw()`.

O que explorar

- As tendências das quatro séries são paralelas ou apresentam direções divergentes ao longo do período?
- Experimente remover o argumento `scales = "free_y"` e compare os dois resultados. Em qual versão as tendências relativas dentro de cada série ficam mais legíveis?
- Alguma série apresenta picos ou quedas pontuais que se destacam do padrão geral de tendência?

4.3 Função de autocorrelação

A função de autocorrelação exibe, para cada defasamento k , a correlação entre a série e sua versão deslocada k posições no tempo. O defasamento 0 tem autocorrelação igual a 1 por definição. As linhas tracejadas no gráfico indicam os limites aproximados de significância estatística: barras que ultrapassam esses limites indicam autocorrelação significativa no defasamento correspondente. Uma série com tendência de crescimento ou redução sistemática produz barras altas e de decaimento lento em vários defasamentos, pois valores próximos no tempo tendem a ser parecidos mesmo para defasamentos maiores.

Código

Use a função `acf()` aplicada à coluna `Moorhen.Kauai` do seu dataset. Inclua o argumento `na.action = na.pass` para lidar com eventuais valores ausentes sem interromper o cálculo. Adicione um título informativo com o argumento `main`.

O que observar

- Quantos defasamentos apresentam autocorrelação além dos limites tracejados?
- O decaimento das barras ao longo dos defasamentos é rápido, com barras significativas apenas nos primeiros defasamentos, ou lento, com barras altas persistindo em muitos defasamentos?
- Compare o gráfico da função de autocorrelação com a série temporal de `Moorhen.Kauai` construída na seção anterior. O padrão de decaimento das barras é coerente com a tendência visual observada na série?

Zuur, Alain F., Elena N. Ieno, Neil J. Walker, Anatoly A. Saveliev, e Graham M. Smith. 2009. *Mixed Effects Models and Extensions in Ecology with R*. Springer.