

# Prática em R - Aula 07

Análise exploratória e visualização de dados

Prof. Fabio Cop (*fcferreira@unifesp.br*)

Instituto do Mar - Unifesp

2026-05-03

## Conteúdo

|          |                                                                                          |          |
|----------|------------------------------------------------------------------------------------------|----------|
| <b>1</b> | <b>Morfometria de passeriformes — distribuição univariada e comparações entre grupos</b> | <b>2</b> |
| 1.1      | Carregamento e inspeção inicial . . . . .                                                | 2        |
| 1.2      | Histograma e escolha de intervalos . . . . .                                             | 2        |
| 1.3      | Curva de densidade . . . . .                                                             | 3        |
| 1.4      | Diagrama de caixa com pontos individuais sobrepostos . . . . .                           | 3        |
| <b>2</b> | <b>Morfometria de passeriformes — relações bivariadas e estrutura multivariada</b>       | <b>4</b> |
| 2.1      | Diagrama de dispersão com variável de grupo . . . . .                                    | 4        |
| 2.2      | Gráfico de pares das variáveis morfométricas . . . . .                                   | 4        |
| 2.3      | Gráfico de pares separado por grupo . . . . .                                            | 5        |
| <b>3</b> | <b>Bioluminescência oceânica — variação entre unidades amostrais</b>                     | <b>5</b> |
| 3.1      | Padrão global profundidade-bioluminescência . . . . .                                    | 5        |
| 3.2      | Variação entre estações com facetas . . . . .                                            | 6        |
| <b>4</b> | <b>Séries temporais e dependência temporal</b>                                           | <b>6</b> |
| 4.1      | Gráfico de série temporal . . . . .                                                      | 6        |
| 4.2      | Comparação de múltiplas séries com facetas . . . . .                                     | 6        |
| 4.3      | Função de autocorrelação . . . . .                                                       | 7        |

## 1 Morfometria de passeriformes — distribuição univariada e comparações entre grupos

O dataset de morfometria de passeriformes de Zuur et al. (2009), arquivo `Sparrows.txt`, registra medidas de comprimento de asa (`wingcrd`), comprimento do tarso (`tarsus`), comprimento do crânio (`head`) e peso corporal (`wt`) para um conjunto de indivíduos, além de variáveis categóricas de sexo (`Sex`, codificada como inteiro) e classe etária (`Age`, também codificada como inteiro). O arquivo usa separador de tabulação.

As atividades desta seção cobrem a exploração da distribuição de variáveis morfométricas individualmente e a comparação dessas distribuições entre grupos. Construa cada visualização de forma independente antes de interpretar os padrões.

### 1.1 Carregamento e inspeção inicial

#### *Código*

Carregue o arquivo com a função `read.table()`, usando `header = TRUE` e `sep = "\t"`. A URL de acesso ao arquivo é:

[https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/\\_bibliography/zuur-2009/zuur-2009-data-sets/Sparrows.txt](https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography/zuur-2009/zuur-2009-data-sets/Sparrows.txt)

Após o carregamento, explore o dataset com as três funções a seguir.

- `str()`: examina o tipo de cada coluna e exibe os primeiros valores.
- `summary()` aplicado às colunas `wingcrd`, `tarsus`, `head` e `wt`: produz o resumo numérico das variáveis morfométricas.
- `table()` aplicado às colunas `Sex` e `Age` separadamente: conta o número de observações em cada categoria.

#### O que observar

- No resultado de `str()`, identifique quais variáveis são numéricas e quais são codificadas como inteiros representando categorias. Essa distinção importa para o mapeamento de cores em `ggplot2`.
- No `summary()`, compare o intervalo de cada variável morfométrica. Para qual variável a diferença entre valor máximo e mínimo é maior em relação à sua mediana?
- A distribuição de machos e fêmeas no dataset é equilibrada ou um dos sexos concentra a maioria das observações?

### 1.2 Histograma e escolha de intervalos

O parâmetro `bins` do `geom_histogram()` controla o número de intervalos do histograma. A escolha do número de intervalos afeta a percepção da forma da distribuição: intervalos em excesso criam variações que dificultam identificar o padrão geral, enquanto intervalos insuficientes suavizam a distribuição a ponto de ocultar detalhes relevantes.

#### *Código*

Construa três histogramas do peso corporal (`wt`) usando `ggplot()` com `geom_histogram()`, variando o argumento `bins` entre os valores 10, 30 e 60. Em cada versão:

- Mapeie `wt` ao eixo  $x$  dentro de `aes()`.
- Use os argumentos `fill` e `color` de `geom_histogram()` para definir a cor de preenchimento das barras e a cor da borda.
- Adicione rótulos aos eixos com `labs()` e aplique `theme_bw()`.

Para exibir os três gráficos lado a lado, carregue o pacote **patchwork** e combine os objetos gerados com o operador **+**.

#### O que explorar

- Em qual das três versões o padrão geral da distribuição de peso corporal fica mais claro?
- Com `bins = 60`, o histograma parece revelar mais detalhes ou mais ruído em relação à versão com `bins = 30`?
- A distribuição do peso corporal parece simétrica em torno de um valor central ou apresenta assimetria? Há barras isoladas nas extremidades que possam indicar valores muito distantes do padrão geral?

### 1.3 Curva de densidade

A curva de densidade é uma versão suavizada do histograma representada como uma curva contínua com área total igual a 1. Ela facilita a comparação da distribuição de uma variável entre grupos na mesma visualização, pois as curvas se sobrepõem de forma contínua sem a interferência visual das barras adjacentes.

#### Código

Construa uma curva de densidade do peso corporal com `ggplot()` e `geom_density()`. Mapeie `factor(Sex)` ao argumento `fill` dentro de `aes()` para separar os grupos por cor. Ajuste o argumento `alpha` em `geom_density()` para tornar as curvas semitransparentes e permitir visualizar as regiões de sobreposição entre os grupos. Adicione rótulos com `labs()` e aplique `theme_bw()`.

Em seguida, posicione o gráfico de densidade ao lado do histograma do peso corporal construído na seção anterior, usando **patchwork**. Para o histograma nessa comparação, use `bins = 30` e mapeie `factor(Sex)` ao argumento `fill` para separar os grupos. Adicione `facet_wrap(~ Sex)` ao histograma para exibir um painel por grupo.

#### O que observar

- As curvas de densidade para machos e fêmeas estão separadas ou se sobrepõem em uma faixa ampla?
- Qual dos dois grupos apresenta curva mais larga, indicando maior dispersão do peso corporal?
- Para comparar a sobreposição entre grupos, qual das duas visualizações você considera mais clara: o histograma com facetas ou a curva de densidade sobreposta?

### 1.4 Diagrama de caixa com pontos individuais sobrepostos

O diagrama de caixa resume a distribuição de uma variável contínua por meio de cinco descritores: o primeiro quartil ( $Q_1$ ), a mediana, o terceiro quartil ( $Q_3$ ), as hastes que se estendem até 1,5 vezes o intervalo interquartil além das bordas da caixa e os pontos além das hastes. A sobreposição dos pontos individuais com `geom_jitter()` torna visível a distribuição real dentro de cada grupo, revelando concentrações e padrões que a caixa isolada não evidencia.

#### Código

Construa um diagrama de caixa do peso corporal por sexo usando `ggplot()` com `geom_boxplot()`. Mapeie `factor(Sex)` ao eixo  $x$  e ao argumento `fill` dentro de `aes()`. Use `outlier.shape = NA` em `geom_boxplot()` para suprimir a marcação automática de valores atípicos, pois os pontos individuais serão exibidos pela camada seguinte. Defina `alpha` para tornar a caixa semitransparente.

Adicione uma camada `geom_jitter()` sobre o diagrama de caixa, ajustando `width`, `alpha` e `size` para equilibrar a visibilidade dos pontos e a sobreposição. Finalize com `labs()` para nomear os eixos e `theme_bw()`.

#### O que observar

- A mediana de machos e fêmeas está em alturas semelhantes ou uma é visivelmente mais alta

do que a outra?

- As caixas dos dois grupos se sobrepõem ou estão separadas? Que proporção do intervalo interquartil de um grupo se encontra dentro do intervalo interquartil do outro?
- Os pontos individuais revelam alguma concentração dentro de cada grupo que a caixa não mostra?

## 2 Morfometria de passeriformes — relações bivariadas e estrutura multivariada

Com a distribuição de cada variável examinada individualmente e as comparações entre grupos realizadas, o passo seguinte é explorar as relações entre pares de variáveis morfométricas. O diagrama de dispersão mostra a direção, a força e a forma de cada relação entre dois pares de variáveis. O gráfico de pares organiza todas as combinações possíveis em uma grade, permitindo uma inspeção multivariada em uma única visualização.

### 2.1 Diagrama de dispersão com variável de grupo

O mapeamento de uma variável categórica à cor dos pontos acrescenta uma terceira dimensão ao diagrama de dispersão, permitindo verificar se a relação entre as variáveis contínuas varia entre os grupos.

#### *Código*

Construa um diagrama de dispersão usando `ggplot()` com `geom_point()`. Mapeie `tarsus` ao eixo `x`, `wingcrd` ao eixo `y` e `factor(Sex)` ao argumento `color`, todos dentro de `aes()`. Use `alpha` em `geom_point()` para reduzir a sobreposição visual dos pontos. Nomeie os eixos e a legenda com `labs()` e aplique `theme_bw()`.

#### O que observar

- A relação entre comprimento do tarso e comprimento de asa é aproximadamente linear ou apresenta curvatura visível?
- A dispersão em torno da relação geral é uniforme ao longo dos valores de `tarsus` ou aumenta conforme o comprimento cresce? Uma dispersão crescente com o preditor é chamada de heterocedasticidade.
- Machos e fêmeas ocupam regiões distintas do espaço tarso-asa ou as nuvens de pontos se sobrepõem amplamente?

### 2.2 Gráfico de pares das variáveis morfométricas

O gráfico de pares exibe, em uma grade, todos os diagramas de dispersão possíveis entre  $p$  variáveis, além da distribuição de cada variável na diagonal. Com quatro variáveis morfométricas, a grade contém  $\frac{4 \times 3}{2} = 6$  pares distintos.

#### *Código*

Carregue o pacote `GGally`. Caso ele não esteja instalado no ambiente do projeto, execute `renv::install("GGally")` uma única vez antes de prosseguir.

Use `select()` do pacote `dplyr` para extrair as colunas `wingcrd`, `tarsus`, `head` e `wt` do dataset. Encadeie com o operador pipe nativo do R (`|>`) e passe o resultado para `ggpairs()` com `aes(alpha = 0.3)`.

#### O que observar

- Identifique o par de variáveis com o maior coeficiente de correlação exibido na parte superior da grade. O diagrama de dispersão correspondente confirma essa associação visualmente?
- Alguma variável apresenta distribuição claramente assimétrica na diagonal da grade? Uma assimetria marcante pode indicar a necessidade de transformação antes da modelagem.
- Há pares de variáveis com coeficiente de correlação próximo de zero? O que isso implica sobre

a informação que cada variável acrescenta a um modelo preditivo?

## 2.3 Gráfico de pares separado por grupo

O argumento `color` dentro do `aes()` de `ggpairs()` aplica a separação por grupo simultaneamente a todos os painéis da grade, permitindo comparar tanto as relações bivariadas quanto as distribuições individuais entre os grupos.

### *Código*

Repita o procedimento da seção anterior, incluindo a coluna `Age` na chamada de `select()`. Mapeie `factor(Age)` ao argumento `color` dentro do `aes()` de `ggpairs()`, mantendo `alpha = 0.3`.

Em seguida, repita a análise substituindo `Age` por `Sex` no mapeamento de cor. Para isso, inclua `Sex` no `select()` e ajuste o `aes()` de acordo.

### O que explorar

- As correlações entre as variáveis morfométricas variam entre classes etárias? Compare os coeficientes de correlação exibidos na parte superior da grade para cada grupo.
- As distribuições na diagonal diferem em localização ou dispersão entre as classes etárias?
- Ao substituir `Age` por `Sex`, as diferenças entre grupos tornam-se mais ou menos pronunciadas do que no agrupamento por idade?

## 3 Bioluminescência oceânica — variação entre unidades amostrais

O dataset de bioluminescência oceânica de Zuur et al. (2009), arquivo `ISIT.txt`, registra contagens de fontes bioluminescentes (`Sources`) em diferentes profundidades de amostragem (`SampleDepth`) em estações do Atlântico Norte. Cada estação (`Station`) corresponde a um local geográfico com múltiplas amostras coletadas em diferentes profundidades. A relação entre profundidade e bioluminescência pode variar entre estações em função de diferenças oceanográficas locais. Examinar se esse padrão é consistente entre locais motiva abordagens de modelagem que estimam a variação entre grupos de forma explícita.

### 3.1 Padrão global profundidade-bioluminescência

#### *Código*

Carregue o arquivo `ISIT.txt` com `read.table()`, usando `header = TRUE` e `sep = "\t"`. A URL de acesso é:

[https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/\\_bibliography/zuur-2009/zuur-2009-data-sets/ISIT.txt](https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography/zuur-2009/zuur-2009-data-sets/ISIT.txt)

Inspecione as variáveis com `str()`. Construa um diagrama de dispersão com `ggplot()` e `geom_point()`, mapeando `SampleDepth` ao eixo  $x$  e `Sources` ao eixo  $y$ . Ajuste `alpha` e `size` para lidar com a sobreposição de pontos. Nomeie os eixos com `labs()` e aplique `theme_bw()`.

### O que observar

- Existe uma tendência visível entre profundidade de amostragem e número de fontes bioluminescentes no padrão global?
- A dispersão dos pontos em torno da tendência geral é pequena e uniforme ou ampla e heterogênea? Alta dispersão pode indicar que estações diferentes apresentam relações distintas com a profundidade.

## 3.2 Variação entre estações com facetas

### Código

Parta do gráfico construído na seção anterior. Acrescente `facet_wrap(~ Station)` como uma camada adicional para dividir o gráfico em painéis por estação amostral. Mantenha os mesmos mapeamentos estéticos, rótulos de eixo e tema.

#### O que observar

- A relação profundidade-bioluminescência é consistente entre as estações ou algumas apresentam padrões claramente distintos das demais?
- A profundidade máxima amostrada varia entre estações, resultando em painéis com diferentes extensões no eixo  $x$ . Em quais estações a relação é mais pronunciada?
- Compare a variação dentro de cada painel com a variação entre os painéis. Em qual escala a variabilidade parece maior?

## 4 Séries temporais e dependência temporal

O dataset de abundâncias de aves aquáticas no Havaí de Zuur et al. (2009), arquivo `Hawaii.txt`, registra contagens anuais de populações de aves endêmicas nas ilhas do Havaí entre 1956 e 2003: pernilongos (`Stilt`) em Oahu e Maui, galinhas-d'água (`Coot`) em Oahu e Maui e galinhola (`Moorhen`) em Kauai. O arquivo também inclui a precipitação anual (`Rainfall`).

O gráfico de série temporal representa uma variável medida repetidamente ao longo do tempo, conectando pontos com linhas para evidenciar tendências de aumento ou redução, flutuações e irregularidades pontuais. Observações coletadas em sequência temporal tendem a ser mais semelhantes entre si quanto mais próximas estiverem no tempo, propriedade chamada de dependência temporal. Essa característica tem implicações importantes para a análise estatística, pois viola a suposição de independência entre observações dos modelos convencionais.

### 4.1 Gráfico de série temporal

#### Código

Carregue o arquivo `Hawaii.txt` com `read.table()` usando `header = TRUE` e `sep = "\t"`. A URL de acesso é:

```
https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography/zuur-2009/zuur-2009-data-sets/Hawaii.txt
```

Inspeccione as variáveis com `str()`. Construa um gráfico de série temporal da coluna `Moorhen.Kauai` ao longo dos anos com `ggplot()`. Use `geom_line()` para conectar os pontos com uma linha e `geom_point()` para destacar cada observação anual. Mapeie `Year` ao eixo  $x$  e `Moorhen.Kauai` ao eixo  $y$ . Defina a cor em ambas as camadas, adicione rótulos de eixo com `labs()` e aplique `theme_bw()`.

#### O que observar

- A abundância de galinhola em Kauai aumenta, diminui ou permanece estável ao longo do período registrado?
- Há algum intervalo de tempo em que a tendência muda de direção ou ocorrem quedas abruptas seguidas de recuperação?
- O padrão geral parece uma tendência contínua ao longo de todo o período ou apresenta variações pontuais em torno de um valor relativamente estável?

### 4.2 Comparação de múltiplas séries com facetas

Quando o dataset contém várias séries temporais, é possível reorganizá-las em formato longo e construir gráficos com facetas, preservando a mesma escala de tempo para comparação visual direta entre as séries. O argumento `scales = "free_y"` em `facet_wrap()` permite que cada painel tenha sua própria escala vertical, facilitando a leitura de tendências relativas quando as séries têm magnitudes muito diferentes entre si.

### Código

Carregue o pacote `tidyr`. Use `select()` para extrair as colunas `Year`, `Stilt.Oahu`, `Stilt.Maui`, `Coot.Oahu` e `Coot.Maui`. Encadeie com `pivot_longer()` para reorganizar as quatro séries em formato longo. No `pivot_longer()`, use `-Year` para indicar que essa coluna permanece como identificador, e nomeie as novas colunas resultantes (uma para o nome da série, outra para os valores de abundância).

Com os dados reorganizados, construa um gráfico com `geom_line()` e aplique `facet_wrap()` usando a coluna de nomes das séries. Inclua `scales = "free_y"` no `facet_wrap()`. Adicione rótulos de eixo com `labs()` e aplique `theme_bw()`.

#### O que explorar

- As tendências das quatro séries são paralelas ou apresentam direções divergentes ao longo do período?
- Experimente remover o argumento `scales = "free_y"` e compare os dois resultados. Em qual versão as tendências relativas dentro de cada série ficam mais legíveis?
- Alguma série apresenta picos ou quedas pontuais que se destacam do padrão geral de tendência?

## 4.3 Função de autocorrelação

A função de autocorrelação exhibe, para cada defasamento  $k$ , a correlação entre a série e sua versão deslocada  $k$  posições no tempo. O defasamento 0 tem autocorrelação igual a 1 por definição. As linhas tracejadas no gráfico indicam os limites aproximados de significância estatística: barras que ultrapassam esses limites indicam autocorrelação significativa no defasamento correspondente. Uma série com tendência de crescimento ou redução sistemática produz barras altas e de decaimento lento em vários defasamentos, pois valores próximos no tempo tendem a ser parecidos mesmo para defasamentos maiores.

### Código

Use a função `acf()` aplicada à coluna `Moorhen.Kauai` do seu dataset. Inclua o argumento `na.action = na.pass` para lidar com eventuais valores ausentes sem interromper o cálculo. Adicione um título informativo com o argumento `main`.

#### O que observar

- Quantos defasamentos apresentam autocorrelação além dos limites tracejados?
- O decaimento das barras ao longo dos defasamentos é rápido, com barras significativas apenas nos primeiros defasamentos, ou lento, com barras altas persistindo em muitos defasamentos?
- Compare o gráfico da função de autocorrelação com a série temporal de `Moorhen.Kauai` construída na seção anterior. O padrão de decaimento das barras é coerente com a tendência visual observada na série?

Zuur, Alain F., Elena N. Ieno, Neil J. Walker, Anatoly A. Saveliev, e Graham M. Smith. 2009. *Mixed Effects Models and Extensions in Ecology with R*. Springer.