

Prática em R

Modelo linear bayesiano: riqueza de espécies bentônicas e nível de maré

Prof. Fabio Cop (*fcferreira@unifesp.br*)

Instituto do Mar - Unifesp

2026-05-14

Conteúdo

1	Exploração dos dados e checagem preditiva a priori	2
1.1	Carregamento e centralização do preditor	2
1.2	Diagrama de dispersão	2
1.3	Distribuições a priori e checagem preditiva a priori	3
2	Ajuste do modelo e distribuição a posteriori	3
2.1	Ajuste do modelo com os dados observados	3
2.2	Resumo da distribuição a posteriori e diagnóstico de convergência	4
2.3	Gráfico de traço das cadeias MCMC	4
3	Faixa de credibilidade, intervalo preditivo e checagem preditiva da posteriori	5
3.1	Faixa de credibilidade e intervalo preditivo	5
3.2	Checagem preditiva da posteriori	5

1 Exploração dos dados e checagem preditiva a priori

O dataset RIKZ (Zuur et al. 2009) registra a riqueza de espécies bentônicas (**Richness**) em 45 estações amostrais distribuídas ao longo de cinco praias do Mar do Norte na Holanda. A variável **NAP** mede o nível de cada estação em relação à maré média local. Valores positivos de **NAP** indicam estações mais elevadas, com períodos mais longos de exposição aérea durante a maré baixa. A variável **Beach** identifica a qual das cinco praias cada estação pertence.

O objetivo desta prática é aplicar o modelo linear bayesiano a um contexto de ecologia marinha. Na leitura prévia, a mesma estrutura de modelo foi usada com dados de altura e peso de adultos. Aqui o contexto muda, mas os três componentes do modelo permanecem idênticos: a distribuição da variável resposta, o preditor linear e as distribuições a priori. Reconhecer esses componentes em um novo cenário é o principal objetivo desta atividade.

1.1 Carregamento e centralização do preditor

O código a seguir carrega o dataset RIKZ e calcula a versão centralizada do preditor **NAP**. Execute-o, inspecione a estrutura dos dados e familiarize-se com as variáveis antes de prosseguir.

Código

```
library(ggplot2)
library(dplyr)
library(brms)
library(posterior)

# Carregar o dataset RIKZ
rikz <- read.table(
  "https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography/zuur-2009/zuur-2009-rikz.csv",
  header = TRUE, sep = "\t"
)

# Inspecionar a estrutura do dataset
str(rikz)

# Centralizar o preditor: NAP_c = NAP - média(NAP)
rikz$NAP_c <- rikz$NAP - mean(rikz$NAP)

# Resumo das variáveis de interesse
summary(rikz[, c("Richness", "NAP", "NAP_c")])
```

O que observar

- Qual é o valor médio de **NAP_c** após a centralização? O resultado é consistente com a operação realizada?
- Compare os resumos de **NAP** e **NAP_c**. O que muda entre as duas variáveis e o que permanece idêntico?
- Qual é o intervalo de valores de **Richness**? Essa variável pode assumir valores negativos?

1.2 Diagrama de dispersão

Antes de especificar qualquer modelo, construa uma visualização da relação entre **NAP_c** e **Richness**. Na leitura prévia, o diagrama de dispersão foi o ponto de partida para identificar a estrutura da relação e motivar a escolha do preditor linear.

Tarefa: Usando `ggplot2`, construa um diagrama de dispersão de `Richness` em função de `NAP_c`. Adicione rótulos informativos aos eixos.

Perguntas de interpretação:

1. Qual é a direção aparente da relação entre `NAP_c` e `Richness`? Estações com NAP centralizado alto tendem a apresentar maior ou menor riqueza de espécies?
2. A relação parece aproximadamente linear ou há curvatura visível na nuvem de pontos?
3. Na leitura prévia, a relação altura-peso tinha direção positiva claramente esperada. Neste contexto ecológico, o sinal de β_1 é igualmente previsível? O que o diagrama sugere?

 Dica

Observe a nuvem de pontos da esquerda para a direita: ela sobe (relação positiva entre NAP e riqueza) ou desce (relação negativa)? A direção que você identificar aqui deve orientar a escolha da distribuição a priori de β_1 na próxima etapa.

1.3 Distribuições a priori e checagem preditiva a priori

Com a relação NAP-riqueza visualizada, especifique as distribuições a priori para os três parâmetros do modelo: β_0 , β_1 e σ .

Tarefa:

1. Defina distribuições a priori para β_0 , β_1 e σ usando a sintaxe `prior(...)` do `brms`. Considere: qual é a riqueza esperada em uma estação com NAP médio? O efeito de NAP pode ser positivo ou negativo?
2. Ajuste o modelo usando apenas as distribuições a priori com o argumento `sample_prior = "only"` no `brm()`.
3. Extraia as amostras com `as_draws_df()` e visualize o feixe de retas simuladas sobre o diagrama de dispersão usando `geom_abline()`.

Perguntas de interpretação:

1. Na leitura prévia, a distribuição a priori de β_1 foi `Lognormal(0,1)`. Por que essa mesma escolha seria inadequada para o coeficiente de `NAP_c` neste contexto ecológico?
2. O feixe de retas simuladas cobre valores de riqueza biologicamente plausíveis? Há retas com riqueza esperada claramente impossível em alguma faixa de NAP?
3. O que acontece com o feixe quando você aumenta bastante o desvio padrão da distribuição a priori de β_1 ? Quando você o diminui muito?

 Dica

A Distribuição Lognormal é definida apenas para valores positivos. Se o coeficiente de regressão pode ser positivo ou negativo, uma distribuição que cobre ambos os lados do zero é mais adequada. Para o intercepto β_0 , pense em qual é a riqueza esperada em uma estação com NAP igual à média: valores entre 5 e 15 espécies seriam plausíveis para praias costeiras temperadas.

2 Ajuste do modelo e distribuição a posteriori

A checagem preditiva a priori avalia se as distribuições a priori são razoáveis antes de observar os dados. O próximo passo é ajustar o modelo com os dados observados. O resultado é a distribuição a posteriori conjunta sobre $(\beta_0, \beta_1, \sigma)$, que combina as distribuições a priori com a informação contida nos dados de riqueza bentônica.

2.1 Ajuste do modelo com os dados observados

Tarefa: Ajuste o modelo linear `Richness ~ NAP_c` com `brm()`, usando as mesmas distribuições a priori e configuração de cadeias da etapa anterior. O argumento que diferenciava a checagem a priori do ajuste completo deve ser removido.

Perguntas de interpretação:

1. Qual é a diferença conceitual entre o objeto gerado aqui e o objeto gerado pela checagem preditiva a priori? De onde vêm as amostras em cada caso?

Dica

O argumento `sample_prior = "only"` foi o que distinguiu a checagem a priori do ajuste completo. Sem ele, o `brm()` usa os dados observados para atualizar as distribuições a priori e gerar a distribuição a posteriori. É exatamente a atualização de crenças descrita pela regra de Bayes: a distribuição a posteriori é proporcional à verossimilhança multiplicada pelas distribuições a priori.

2.2 Resumo da distribuição a posteriori e diagnóstico de convergência

Antes de interpretar qualquer estimativa, é necessário verificar se as cadeias MCMC convergiram. Dois critérios são centrais:

- **R-hat** ($\hat{R}$): valores abaixo de 1,01 indicam convergência adequada.
- **Bulk ESS** (tamanho efetivo da amostra): valores acima de 400 indicam estimativas precisas.

Tarefa:

1. Extraia as amostras da distribuição a posteriori com `as_draws_df()`.
2. Calcule o resumo com `summarise_draws()`, usando a média, o desvio padrão e os quantis 2,5% e 97,5% (intervalo de credibilidade de 95%).
3. Verifique os diagnósticos de convergência com `summary()` aplicado ao objeto ajustado.

Perguntas de interpretação:

1. Os critérios de convergência foram satisfeitos ($\hat{R} < 1,01$ e Bulk ESS > 400 para β_0 , β_1 e σ)?
2. Qual é o sinal da média a posteriori de β_1 ? O intervalo de credibilidade de 95% inclui zero ou exclui completamente um dos lados? O que isso indica sobre a relação NAP-riqueza?
3. Como interpretar o valor de β_0 neste contexto ecológico? Esse valor é biologicamente razoável para estações com NAP médio em praias costeiras?

Dica

O diagnóstico de convergência deve sempre preceder a interpretação substantiva dos parâmetros. Se $\hat{R} > 1,01$ para algum parâmetro, os resultados não são confiáveis independentemente dos valores estimados. Verifique R-hat e Bulk ESS antes de olhar para os valores de β_0 , β_1 e σ .

2.3 Gráfico de traço das cadeias MCMC

O gráfico de traço exibe o valor amostrado de cada parâmetro ao longo das iterações de cada cadeia. Ele oferece uma visualização direta da qualidade da mistura das cadeias.

Tarefa: Construa o gráfico de traço com `mcmc_trace()` do pacote `bayesplot`, passando os nomes dos parâmetros `"b_Intercept"`, `"b_NAP_c"` e `"sigma"`.

Perguntas de interpretação:

1. As quatro cadeias se misturam densamente na mesma região ou alguma cadeia se afasta das demais por várias iterações consecutivas?
2. Há alguma tendência de crescimento ou redução sistemática ao longo das iterações?
3. O padrão de mistura do gráfico de traço é coerente com os valores de R-hat observados na etapa anterior?

Dica

Um gráfico de traço com boa mistura apresenta as quatro cadeias sobrepostas de forma densa ao redor de um valor estável, sem períodos prolongados de separação entre cadeias e sem tendências

visíveis de subida ou descida. Quando o gráfico de traço tem essa aparência, o R-hat tende a estar próximo de 1.

3 Faixa de credibilidade, intervalo preditivo e checagem preditiva da posteriori

A distribuição a posteriori permite calcular duas quantidades distintas para descrever a incerteza sobre as predições. A diferença entre elas está nas fontes de incerteza que cada uma captura. Na leitura prévia, a distinção foi apresentada por meio de uma analogia: a faixa de credibilidade corresponde à incerteza sobre onde está a linha de previsão, enquanto o intervalo preditivo corresponde à incerteza sobre o valor que uma observação específica assumirá.

3.1 Faixa de credibilidade e intervalo preditivo

Tarefa:

1. Crie um `data.frame` com 100 valores de `NAP_c` cobrindo a faixa observada no dataset.
2. Calcule a faixa de credibilidade da resposta média com `posterior_epred()` e o intervalo preditivo com `posterior_predict()`, ambos aplicados ao objeto ajustado e aos novos dados.
3. Calcule os resumos (média e quantis 2,5% e 97,5%) para cada posição de predição com `apply()`.
4. Visualize as duas bandas sobrepostas com `geom_ribbon()` e a reta média com `geom_line()`.

Perguntas de interpretação:

1. Qual das duas bandas é mais larga? Que fontes de incerteza cada uma captura?
2. A diferença de largura entre as duas bandas reflete a incerteza adicional de σ no intervalo preditivo. Em que região da faixa de NAP essa diferença é mais pronunciada?
3. O limite inferior do intervalo preditivo inclui valores negativos de riqueza em alguma faixa de NAP? O que isso revela sobre a adequação do modelo Normal para dados de contagem de espécies?

 Dica

`posterior_epred()` captura somente a incerteza sobre β_0 e β_1 : onde está a reta. `posterior_predict()` acrescenta a variabilidade individual capturada por σ : onde cairia uma nova observação. O intervalo preditivo é sempre mais largo porque inclui essa fonte adicional de variabilidade. A função usada determina o que está sendo estimado: a reta média ou uma observação futura.

3.2 Checagem preditiva da posteriori

A checagem preditiva da posteriori compara a distribuição dos dados observados com a distribuição dos dados simulados a partir do modelo ajustado. Ela difere da checagem preditiva a priori: aqui o modelo já foi ajustado aos dados, e a comparação avalia se os dados simulados são compatíveis com os dados reais.

Tarefa: Use `pp_check()` com `ndraws = 100` para comparar a distribuição observada de `Richness` com as distribuições simuladas pelo modelo ajustado.

Perguntas de interpretação:

1. A linha escura (distribuição observada) e as linhas coloridas claras (distribuições simuladas) apresentam formas semelhantes em relação à posição central, dispersão e assimetria?
2. O modelo simula valores de riqueza que seriam impossíveis para uma variável de contagem de espécies? Em qual região do gráfico essa limitação é mais visível?
3. Em que essa checagem preditiva da posteriori difere da checagem preditiva a priori realizada anteriormente? O que muda entre as duas verificações?

 Dica

Uma distribuição Normal pode simular valores em toda a reta real, incluindo valores negativos. Para uma variável de contagem de espécies, valores negativos são impossíveis. A checagem preditiva da posteriori torna essa limitação visível e motiva a investigação de outras distribuições de probabilidade mais adequadas para dados de contagem.

Zuur, Alain F., Elena N. Ieno, Neil J. Walker, Anatoly A. Saveliev, e Graham M. Smith. 2009. *Mixed Effects Models and Extensions in Ecology with R*. Springer.