

Prática em R

Modelo de Poisson para dados de contagem

Prof. Fabio Cop (*fcferreira@unifesp.br*)

Instituto do Mar - Unifesp

2026-05-18

Conteúdo

1	Carregamento dos dados e inspeção inicial	2
1.1	Carregamento e centralização do preditor	2
1.2	Richness como variável de contagem	3
1.3	Diagrama de dispersão	3
2	O modelo Normal como referência	4
2.1	Ajuste do modelo Normal e checagem da posteriori	4
3	Especificação do modelo de Poisson	4
3.1	Raciocínio sobre as distribuições a priori na escala log	4
3.2	Checagem preditiva a priori	5
4	Ajuste do modelo de Poisson e diagnóstico de convergência	5
4.1	Ajuste com os dados observados	5
4.2	Diagnóstico de convergência	6
4.3	Interpretação na escala de contagem	6
5	Taxa esperada e checagem preditiva da posteriori	7
5.1	Faixa de credibilidade da taxa esperada	7
5.2	Intervalo preditivo para novas contagens	7
5.3	Checagem preditiva da posteriori e comparação final	8

1 Carregamento dos dados e inspeção inicial

O dataset RIKZ (Zuur et al. 2009) registra a riqueza de espécies bentônicas (**Richness**) em 45 estações amostrais distribuídas ao longo de cinco praias do Mar do Norte na Holanda. A variável **NAP** mede o nível de cada estação em relação à maré média local. A variável **Richness** é uma contagem do número de espécies registradas em cada estação, portanto um inteiro não negativo. Essa característica tem consequências diretas para a escolha do modelo estatístico.

1.1 Carregamento e centralização do preditor

O código a seguir carrega os pacotes necessários, importa o dataset e calcula a versão centralizada do preditor NAP. Execute-o e inspecione o resultado antes de prosseguir.

Código

```
library(tidyverse)
library(brms)
library(posterior)
library(bayesplot)

# Carregar o dataset RIKZ
rikz <- read.table(
  "https://raw.githubusercontent.com/FCopf/prob-est-2026/refs/heads/main/_bibliography/zuur-2009/zuur-2009-rikz.csv",
  header = TRUE,
  sep = "\t"
)

# Centralizar o preditor: NAP_c = NAP - média(NAP)
rikz$NAP_c <- rikz$NAP - mean(rikz$NAP)

# Inspeccionar as variáveis de interesse
str(rikz)
```

```
'data.frame': 45 obs. of 6 variables:
 $ Sample : int 1 2 3 4 5 6 7 8 9 10 ...
 $ Richness: int 11 10 13 11 10 8 9 8 19 17 ...
 $ Exposure: int 10 10 10 10 10 8 8 8 8 8 ...
 $ NAP : num 0.045 -1.036 -1.336 0.616 -0.684 ...
 $ Beach : int 1 1 1 1 1 2 2 2 2 2 ...
 $ NAP_c : num -0.303 -1.384 -1.684 0.268 -1.032 ...
```

```
summary(rikz[, c("Richness", "NAP", "NAP_c", "Beach")])
```

Richness	NAP	NAP_c	Beach
Min. : 0.000	Min. : -1.3360	Min. : -1.6837	Min. : 1
1st Qu.: 3.000	1st Qu.: -0.3750	1st Qu.: -0.7227	1st Qu.: 3
Median : 4.000	Median : 0.1670	Median : -0.1807	Median : 5
Mean : 5.689	Mean : 0.3477	Mean : 0.0000	Mean : 5
3rd Qu.: 8.000	3rd Qu.: 1.1170	3rd Qu.: 0.7693	3rd Qu.: 7
Max. : 22.000	Max. : 2.2550	Max. : 1.9073	Max. : 9

O que observar

- Quais são o mínimo e o máximo de **Richness**? Essa variável pode assumir valores negativos?

- O que muda entre os resumos de `NAP` e `NAP_c` e o que permanece idêntico?
- Quantas praias (`Beach`) estão representadas no dataset?

1.2 Richness como variável de contagem

A variável `Richness` registra o número de espécies encontradas em cada estação. Por ser uma contagem de objetos discretos, seus valores são inteiros não negativos: 0, 1, 2, 3 e assim por diante. Compreender essa natureza é o ponto de partida para justificar a troca da Distribuição Normal pela Distribuição de Poisson.

Tarefa:

1. Construa um histograma de `Richness` com `geom_histogram()`, usando `binwidth = 1`.
2. Calcule a média e a variância de `Richness` com `mean()` e `var()` e compare os dois valores.

Perguntas de interpretação:

1. O histograma de `Richness` apresenta forma simétrica ou assimétrica? Para que lado a distribuição se concentra?
2. Na leitura prévia, a Distribuição de Poisson possui uma propriedade chamada equidispersão: a média e a variância são iguais ao parâmetro λ . Os valores calculados para `Richness` estão próximos entre si?
3. Uma Distribuição Normal é contínua e atribui probabilidade positiva a qualquer valor real. Por que essa característica a torna inadequada para modelar `Richness`?

Dica

Uma variável de contagem tem valores inteiros e não negativos, com frequência concentrada nos valores menores e assimetria à direita. Uma Distribuição Normal centrada nessa média geraria valores negativos com probabilidade positiva. Observe também a relação entre a média e a variância calculadas: quanto mais próximas estiverem, mais compatível é a hipótese de equidispersão da Distribuição de Poisson.

1.3 Diagrama de dispersão

Com a natureza de `Richness` estabelecida, visualize a relação entre riqueza de espécies e nível de maré centralizado.

Tarefa: Construa um diagrama de dispersão de `Richness` em função de `NAP_c` com `ggplot2`. Adicione rótulos informativos aos eixos.

Perguntas de interpretação:

1. A relação entre `NAP_c` e `Richness` parece positiva ou negativa? Estações com `NAP` centralizado mais alto tendem a apresentar maior ou menor riqueza?
2. Os valores de `Richness` são inteiros? Há muitos zeros na amostra?
3. A dispersão dos pontos ao redor da tendência central parece constante ao longo de toda a faixa de `NAP_c` ou varia?

Dica

Observe a nuvem de pontos da esquerda para a direita: ela sobe ou desce? Estações mais elevadas ficam expostas ao ar por períodos mais longos durante a maré baixa, o que tende a criar condições mais adversas para organismos marinhos bentônicos. O padrão visual sugere o sinal esperado para o coeficiente β_1 do modelo.

2 O modelo Normal como referência

Antes de especificar o modelo de Poisson, é instrutivo ajustar um modelo Normal para os mesmos dados e examinar sua checagem preditiva da posteriori. Essa etapa torna visível a limitação estrutural que motiva a troca de distribuição.

2.1 Ajuste do modelo Normal e checagem da posteriori

Tarefa:

1. Especifique distribuições a priori para β_0 , β_1 e σ com a sintaxe `prior()` do `brms`. Considere: qual é a riqueza esperada em uma estação com NAP médio? O efeito de NAP pode ser positivo ou negativo?
2. Ajuste o modelo Normal com `brm(formula = Richness ~ NAP_c, family = gaussian(), ...)`.
3. Execute `pp_check(fit_rikz_normal, ndraws = 100)` e observe as distribuições simuladas.

Perguntas de interpretação:

1. As distribuições simuladas pelo modelo Normal incluem valores negativos de riqueza em alguma faixa de NAP_c? Valores negativos de número de espécies são biologicamente possíveis?
2. A distribuição observada de `Richness` (linha escura no `pp_check`) é simétrica ou assimétrica? As distribuições simuladas pelo modelo Normal reproduzem essa assimetria?
3. Qual é a limitação estrutural que impede o modelo Normal de capturar adequadamente uma variável de contagem?

Dica

No `pp_check()`, a linha escura é a distribuição observada de `Richness`. As linhas coloridas são distribuições simuladas pelo modelo ajustado. Se as linhas simuladas se estendem para valores negativos, o modelo está gerando dados impossíveis para uma contagem de espécies. Observe também se a forma das distribuições simuladas reproduz a assimetria da distribuição observada.

3 Especificação do modelo de Poisson

A leitura prévia apresentou a estrutura do GLM de Poisson. O modelo substitui a Distribuição Normal pela Distribuição de Poisson como verossimilhança e conecta a taxa esperada λ_i ao preditor linear por meio da função de ligação logarítmica:

$$\begin{aligned} \text{Richness}_i &\sim \text{Poisson}(\lambda_i) \\ \log(\lambda_i) &= \beta_0 + \beta_1 \cdot \text{NAP}_{c,i} \end{aligned}$$

A função de ligação log garante que $\lambda_i > 0$ para qualquer valor de β_0 , β_1 e $\text{NAP}_{c,i}$. As distribuições a priori são especificadas na escala logarítmica, porque os parâmetros β_0 e β_1 operam sobre $\log(\lambda_i)$, não diretamente sobre λ_i .

3.1 Raciocínio sobre as distribuições a priori na escala log

Tarefa:

1. Use `exp()` para calcular a taxa esperada de riqueza correspondente a alguns valores de β_0 : por exemplo, `exp(1.5)` e `exp(2.0)`. Esses valores são compatíveis com o contexto ecológico?
2. Interprete o que significa $\beta_1 = -0,5$ na escala de contagem usando `exp(-0.5)`. Quanto a taxa esperada de riqueza se multiplica por unidade adicional de NAP_c?
3. Defina as distribuições a priori `Normal(1.5, 1)` para β_0 e `Normal(0, 0.5)` para β_1 .

Perguntas de interpretação:

1. O valor `exp(1.5)` corresponde a quantas espécies? Esse valor é razoável como riqueza esperada em estações com NAP médio, considerando o histograma construído na seção anterior?

2. A leitura prévia descreve como especificar distribuições a priori na escala log a partir de uma taxa plausível. Por que a escala de β_0 não é a mesma que a escala de riqueza de espécies?
3. Um valor de $|\beta_1| = 1$ implicaria multiplicar ou dividir a taxa esperada por $e \approx 2,7$ a cada unidade de NAP_c. Por que uma distribuição a priori $\text{Normal}(0, 0,5)$ é mais moderada do que $\text{Normal}(0, 2)$?

Dica

O raciocínio para β_0 parte de uma taxa esperada plausível para estações com NAP médio e toma o logaritmo: se você espera entre 4 e 6 espécies, então $\log(4) \approx 1,4$ e $\log(6) \approx 1,8$. Uma distribuição $\text{Normal}(1,5, 1)$ coloca 95% da probabilidade entre $e^{-0,5} \approx 0,6$ e $e^{3,5} \approx 33$ espécies, cobrindo uma faixa ampla e biologicamente plausível.

3.2 Checagem preditiva a priori

A checagem preditiva a priori verifica se as distribuições a priori especificadas geram contagens plausíveis antes de observar os dados. O procedimento usa `sample_prior = "only"`, o mesmo argumento introduzido na aula anterior para o modelo Normal.

Tarefa:

1. Use o argumento `sample_prior = "only"` no `brm()` para ajustar o modelo de Poisson usando apenas as distribuições a priori.
2. Aplique `pp_check()` ao objeto resultante com `ndraws = 100` e observe as distribuições simuladas.
3. Compare as contagens simuladas com a faixa observada de `Richness` no dataset.

Perguntas de interpretação:

1. As distribuições simuladas pela checagem a priori do modelo de Poisson incluem valores negativos? Compare com o resultado obtido com o modelo Normal.
2. A faixa de contagens simuladas é compatível com o contexto ecológico? Contagens na casa dos milhares seriam implausíveis para riqueza bentônica em praias temperadas.
3. Em que aspecto a checagem preditiva a priori do modelo de Poisson difere conceitualmente da mesma checagem feita para o modelo Normal na seção anterior?

Dica

A função de ligação logarítmica garante que $\lambda_i = e^{\beta_0 + \beta_1 x_i} > 0$ para qualquer combinação de parâmetros e covariável. Por isso, o modelo de Poisson nunca simula contagens negativas, independentemente das distribuições a priori. Se a faixa simulada for muito ampla (milhares de espécies), ajuste o desvio padrão de β_0 para valores menores.

4 Ajuste do modelo de Poisson e diagnóstico de convergência

4.1 Ajuste com os dados observados

Com as distribuições a priori verificadas, o próximo passo é ajustar o modelo de Poisson aos dados observados. O código é o mesmo da checagem a priori, com a remoção do argumento `sample_prior = "only"`.

Tarefa:

1. Ajuste o modelo de Poisson `Richness ~ NAP_c` com `brm()`, usando as mesmas distribuições a priori e configuração de cadeias. Remova apenas o argumento `sample_prior = "only"`.
2. Visualize o resumo do ajuste com `summary()`.

Perguntas de interpretação:

1. Qual é a diferença conceitual entre o objeto gerado aqui e o objeto gerado na checagem preditiva a priori? De onde vêm as amostras em cada caso?
2. Os parâmetros `b_Intercept` e `b_NAP_c` exibidos no resumo estão na escala de contagem ou na escala logarítmica?

Dica

Remover `sample_prior = "only"` instrui o `brm()` a usar os dados observados para atualizar as distribuições a priori via regra de Bayes. As amostras da distribuição a posteriori descrevem os valores de β_0 e β_1 que são consistentes tanto com as distribuições a priori quanto com os dados observados. Os valores do resumo estão na escala log e precisarão de transformação para interpretação direta em contagens.

4.2 Diagnóstico de convergência

Antes de interpretar qualquer parâmetro, é necessário verificar se as cadeias MCMC convergiram. Os critérios são os mesmos estabelecidos na aula anterior:

- **R-hat** ($\hat{R}$): valores abaixo de 1,01 indicam convergência adequada.
- **Bulk ESS** (tamanho efetivo da amostra): valores acima de 400 indicam estimativas precisas.

Tarefa:

1. Extraia as amostras da distribuição a posteriori com `as_draws_df()`.
2. Calcule o resumo com `summarise_draws()`, incluindo `mean`, `sd`, `rhat`, `ess_bulk`, `ess_tail` e os quantis 2,5% e 97,5%.
3. Construa o gráfico de traço com `mcmc_trace()` para `"b_Intercept"` e `"b_NAP_c"`.

Perguntas de interpretação:

1. Os valores de $\hat{R}$ estão abaixo de 1,01 para os dois parâmetros?
2. Os valores de Bulk ESS estão acima de 400?
3. As quatro cadeias no gráfico de traço se misturam densamente na mesma região ou alguma se separa das demais por várias iterações consecutivas?

Dica

O diagnóstico de convergência deve sempre preceder a interpretação dos parâmetros. Um $\hat{R}$ próximo de 1 e cadeias bem misturadas no gráfico de traço indicam que as amostras representam adequadamente a distribuição a posteriori. Se $\hat{R} > 1,01$ para algum parâmetro, os resultados não são confiáveis, independentemente dos valores estimados.

4.3 Interpretação na escala de contagem

Os parâmetros do modelo de Poisson estão na escala logarítmica. Para interpretar os efeitos em termos de contagens de espécies, aplique `exp()` às amostras da distribuição a posteriori.

A leitura prévia apresentou as seguintes regras de interpretação:

- **Intercepto** β_0 : quando `NAP_c = 0` (nível médio de maré), a taxa esperada de riqueza é e^{β_0} .
- **Coefficiente** β_1 : cada unidade adicional de `NAP_c` multiplica a taxa esperada por e^{β_1} .

Tarefa:

1. Aplique `exp()` às amostras de `b_Intercept`. O resultado é a distribuição a posteriori da taxa esperada de riqueza em estações com NAP médio.
2. Aplique `exp()` às amostras de `b_NAP_c`. O resultado é a distribuição a posteriori do fator multiplicativo por unidade de `NAP_c`.
3. Resuma as duas quantidades com `mean()` e `quantile()`, usando o intervalo de credibilidade de 95%.

Perguntas de interpretação:

1. Qual é a taxa esperada de riqueza em estações com NAP médio (`NAP_c = 0`)?
2. O fator multiplicativo de `b_NAP_c` é maior ou menor do que 1? O que isso indica sobre a direção do efeito do nível de maré sobre a riqueza?
3. O intervalo de credibilidade de 95% para o fator multiplicativo inclui o valor 1? O que significa um fator multiplicativo igual a 1 para o coeficiente β_1 ?

Dica

Na leitura prévia, a interpretação multiplicativa é descrita assim: quando $\beta_1 < 0$, a taxa esperada é multiplicada por $e^{\beta_1} < 1$ a cada unidade adicional da covariável, o que equivale a uma redução percentual na contagem esperada. Um intervalo de credibilidade de 95% para o fator multiplicativo que não inclui 1 indica que a direção do efeito é consistente na distribuição a posteriori. Compare o fator multiplicativo com 1: acima de 1 indica aumento, abaixo de 1 indica redução.

5 Taxa esperada e checagem preditiva da posteriori

5.1 Faixa de credibilidade da taxa esperada

A função `posterior_epred()` calcula a taxa esperada λ_i para cada valor de `NAP_c`, integrando sobre a distribuição a posteriori de β_0 e β_1 . A curva resultante mostra como a riqueza esperada varia ao longo do nível de maré.

Tarefa:

1. Crie um `data.frame` com 100 valores de `NAP_c` cobrindo a faixa observada no dataset.
2. Calcule a taxa esperada com `posterior_epred()` e construa o resumo da média e dos quantis 2,5% e 97,5% com `apply()`.
3. Visualize a curva média e a faixa de credibilidade sobrepostas ao diagrama de dispersão.

Perguntas de interpretação:

1. A relação ajustada entre `NAP_c` e a taxa esperada de riqueza é uma reta ou uma curva? Por que o modelo de Poisson produz esse formato?
2. Em qual faixa de `NAP_c` a faixa de credibilidade da taxa esperada é mais estreita? Em qual é mais larga?
3. A curva ajustada captura o padrão geral da nuvem de pontos observados?

Dica

No modelo Normal da aula anterior, a relação ajustada era sempre uma reta porque o preditor linear operava diretamente sobre a média μ_i . No modelo de Poisson, o preditor linear opera sobre $\log(\lambda_i)$. Ao retornar à escala original via exponenciação, a relação linear na escala log se transforma em uma curva exponencial na escala de contagem. Quando $\beta_1 < 0$, a curva decresce.

5.2 Intervalo preditivo para novas contagens

A função `posterior_predict()` simula novas contagens individuais a partir da distribuição preditiva da posteriori. O intervalo preditivo descreve onde se espera encontrar a maioria das contagens de novas estações para cada valor de `NAP_c`.

Tarefa:

1. Calcule o intervalo preditivo com `posterior_predict()` usando os mesmos novos dados criados na etapa anterior.
2. Construa o resumo dos quantis 2,5% e 97,5% com `apply()`.
3. Sobreponha o intervalo preditivo (banda laranja) à faixa de credibilidade da taxa esperada (banda azul) no mesmo gráfico.

Perguntas de interpretação:

1. Qual das duas bandas é mais larga? Que fontes de incerteza cada uma captura?
2. Em qual região de `NAP_c` a diferença de largura entre as duas bandas é mais pronunciada?
3. Na leitura prévia, a Distribuição de Poisson tem variância igual à média: $\text{Var}[Y] = E[Y] = \lambda$. Como essa propriedade se manifesta na largura do intervalo preditivo ao longo da curva?

Dica

`posterior_epred()` captura apenas a incerteza sobre a curva média (β_0 e β_1). `posterior_predict()` acrescenta a variabilidade individual da Distribuição de Poisson. Como a variância da Distribuição de Poisson é igual à taxa esperada, regiões com λ_i alto têm mais variabilidade absoluta nas contagens individuais. Isso significa que o intervalo preditivo fica mais largo onde a curva média é mais alta.

5.3 Checagem preditiva da posteriori e comparação final

A etapa final compara a distribuição observada de **Richness** com as distribuições simuladas pelos dois modelos. Essa comparação consolida a motivação para o modelo de Poisson.

Tarefa:

1. Execute `pp_check()` com `ndraws = 100` para o modelo Normal (`fit_rikz_normal`).
2. Execute `pp_check()` com `ndraws = 100` para o modelo de Poisson (`fit_rikz_pois`).
3. Compare os dois gráficos e identifique as diferenças entre as distribuições simuladas.

Perguntas de interpretação:

1. O modelo Normal simula valores negativos de riqueza? O modelo de Poisson apresenta o mesmo problema?
2. Qual dos dois modelos reproduz melhor a assimetria e a natureza discreta da distribuição observada de **Richness**?
3. Ainda que o modelo de Poisson represente uma melhora em relação ao Normal, há alguma discrepância visível entre os dados observados e as distribuições simuladas pelo modelo de Poisson? O que essa discrepância poderia indicar sobre a adequação do modelo?

Dica

No `pp_check()`, a linha escura é a distribuição observada de **Richness**. Cada linha colorida clara é uma distribuição simulada pelo modelo ajustado. O modelo Normal permite valores negativos e tende a gerar distribuições mais simétricas. O modelo de Poisson restringe as simulações a inteiros não negativos. Se as distribuições simuladas pelo modelo de Poisson ainda apresentarem alguma discrepância com a distribuição observada, isso pode indicar que o modelo de Poisson simples não captura toda a estrutura dos dados.

Zuur, Alain F., Elena N. Ieno, Neil J. Walker, Anatoly A. Saveliev, e Graham M. Smith. 2009. *Mixed Effects Models and Extensions in Ecology with R*. Springer.